



МИНОБРНАУКИ РОССИИ  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования

«МИРЭА – Российский технологический университет»

**РТУ МИРЭА**

---

**Институт информационных технологий (ИИТ)**

**Кафедра прикладной математики (ПМ)**

## **КУРСОВАЯ РАБОТА**

по дисциплине «Прикладные задачи математической статистики»

**Тема курсовой работы: «Статистический анализ уровня озона в атмосфере методами математической статистики с целью выявления экологических последствий»**

Студент группы ИНБО-21-23      Илюхин Кирилл Николаевич

  
(подпись)

Руководитель  
курсовой работы

Ст. Преподаватель Парамонов А.А.

  
(подпись)

Работа представлена к защите «\_\_» \_\_\_\_\_ 2025 г.


Допущен к защите «\_\_» \_\_\_\_\_ 2025 г.

Москва 2025 г.



МИНОБРНАУКИ РОССИИ  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«МИРЭА – Российский технологический университет»  
РТУ МИРЭА

Институт информационных технологий (ИИТ)  
Кафедра прикладной математики (ПМ)

Утверждаю  
Заведующий кафедрой ПМ  
  
(подпись) Смоленцева Т.Е.  
«22» сентября 2025 г.

**ЗАДАНИЕ**  
на выполнение курсовой работы  
по дисциплине «Прикладные задачи математической статистики»

Студент Илюхин Кирилл Николаевич

Группа ИНБО-21-23

Тема «Статистический анализ уровня озона в атмосфере методами математической статистики с целью выявления экологических последствий»

Исходные данные: область анализа, назначенная студенту согласно теме работы и реальные данные из открытых источников

**Перечень вопросов, подлежащих разработке, и обязательного графического материала:**

Обоснование актуальности темы, формулировка цели, задач, объекта и предмета анализа, краткая характеристика данных; Выполнение предварительного анализа: построение вариационных рядов, гистограмм, эмпирических функций распределения, расчёт выборочных характеристик и точечных оценок с анализом их свойств; Расчёт доверительных интервалов, подбор подходящих статистических критериев и обоснование их выбора, проведение проверки статистических гипотез с использованием параметрических и непараметрических методов; Проведение оценки распределений и плотностей, сравнение результатов с теоретическими моделями, анализ совпадения или расхождения результатов; Определение закона распределения данных с помощью критерия согласия Пирсона и метода анаморфоз, построение графиков и сравнение результатов обоих методов.

**Срок представления к защите курсовой работы:**

Задание на курсовую работу выдал

  
Подпись руководителя

до «19» декабря 2025 г.

Парамонов А.А.

(ФИО руководителя)

«19» сентября 2025 г.

Илюхин К.Н.

(ФИО обучающегося)

«19» сентября 2025 г.

Задание на курсовую работу получил

  
Подпись обучающегося

# СОДЕРЖАНИЕ

|                                                                                 |    |
|---------------------------------------------------------------------------------|----|
| СОДЕРЖАНИЕ.....                                                                 | 3  |
| ВВЕДЕНИЕ.....                                                                   | 4  |
| 1 СБОР И ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ.....                                     | 6  |
| 1.1 Анализ целевой переменной .....                                             | 6  |
| 1.2 Анализ вспомогательного признака .....                                      | 22 |
| 2 ОЦЕНКА ПАРАМЕТРОВ РАСПРЕДЕЛЕНИЯ .....                                         | 33 |
| 2.1 Оценка параметров распределения целевой переменной .....                    | 33 |
| 3 идентифицирование распределения исследуемых данных.....                       | 53 |
| 3.1 ИДЕНТИФИЦИРОВАНИЕ РАСПРЕДЕЛЕНИЯ С ПОМОЩЬЮ<br>КРИТЕРИЯ СОГЛАСИЯ ПИРСОНА..... | 53 |
| 3.2 ИДЕНТИФИЦИРОВАНИЕ РАСПРЕДЕЛЕНИЯ С ПОМОЩЬЮ МЕТОДА<br>АНАМАРФОЗ.....          | 58 |
| 4 Заключение.....                                                               | 63 |
| СПИСОК ИСТОЧНИКОВ .....                                                         | 66 |

# ВВЕДЕНИЕ

В современном мире качество атмосферного воздуха является одной из ключевых экологических проблем, оказывающих прямое влияние на здоровье человека и состояние экосистем. Интенсивная урбанизация, рост промышленного производства и транспортной нагрузки приводят к накоплению загрязняющих веществ в атмосфере, среди которых особое значение имеет озон. Избыточная концентрация озона в приземном слое атмосферы способна вызывать заболевания дыхательной системы, снижать продуктивность растений и способствовать изменению климатических условий. Поэтому анализ динамики озона и факторов, влияющих на его образование, становится важной задачей как для науки, так и для экологического контроля.

Атмосферная экология и мониторинг качества воздуха охватывают широкий спектр дисциплин — от химии и физики атмосферы до метеорологии и биоиндикаторов загрязнения. Методы математической статистики позволяют систематизировать и анализировать большие объемы данных, выявлять закономерности и оценивать влияние различных факторов на концентрацию загрязнителей. Применение статистических методов к данным о концентрациях озона и его прекурсоров (например, оксидов азота и углеводородов) позволяет не только описывать текущую ситуацию, но и прогнозировать возможные экологические последствия, выявлять сезонные и суточные колебания и определять взаимосвязи между химическими и метеорологическими параметрами.

Целью данной работы является статистический анализ уровня озона в атмосфере с использованием методов математической статистики и выявление потенциальных экологических последствий. Для достижения этой цели определены следующие задачи:

- провести сбор и систематизацию исходных данных о концентрациях озона, его прекурсоров и метеорологических

параметрах, рассчитать основные статистические характеристики, такие как среднее, дисперсия, коэффициент вариации, построить гистограммы и эмпирические функции распределения;

- оценить параметры распределений концентраций загрязнителей с использованием методов моментных и максимального правдоподобия, построить доверительные интервалы и проверить свойства оценок (несмещённость, состоятельность, эффективность);
- исследовать взаимосвязи между концентрацией озона и факторами, влияющими на его образование, с помощью корреляционного и регрессионного анализа, а также выявить характер сезонных и суточных изменений уровня озона методом анализа временных рядов;
- провести проверку статистических гипотез, определяя значимость влияния прекурсоров и метеорологических условий на уровень озона, и оценить потенциальные экологические последствия для городских экосистем.

Реализация этих задач позволит получить количественные и качественные выводы о динамике озона в атмосфере, оценить влияние основных факторов и внести рекомендации по мониторингу и управлению качеством воздуха в урбанизированных регионах.

# 1 СБОР И ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ

## 1.1 Анализ целевой переменной

В данном разделе рассматриваются исходные данные, используемые для статистического анализа концентраций озона в атмосфере с целью выявления закономерностей и экологических последствий загрязнения воздуха. Данные относятся к области атмосферной экологии, экологической химии и метеорологии, где методы математической статистики применяются для обработки больших массивов информации о концентрациях загрязняющих веществ и метеорологических показателях. Анализ этих данных позволяет оценить влияние антропогенных и природных факторов на уровень озона, выявить сезонные и суточные колебания концентраций, а также оценить потенциальные риски для здоровья населения и экосистем.

Исходные данные взяты из открытого репозитория машинного обучения UCI [1] и представляют собой набор измерений качества воздуха, собранных с помощью многопараметрического химического сенсора (Air Quality Chemical Multisensor Device) на наземной станции в итальянском городе. Данные включают почасовые измерения с марта 2004 по февраль 2005 года, что обеспечивает высокую временную детализацию для анализа временных рядов и сезонных трендов. Для анализа выбран основной показатель — сопротивление сенсора  $PT08.S5(O_3)$ , которое косвенно отражает концентрацию озона в приземном слое атмосферы. Эта переменная позволяет количественно оценить уровень загрязнения и выявить динамику его изменения во времени.

Набор данных включает как числовые, так и категориальные переменные. Основные столбцы и их описание представлены в Таблице 1.

Таблица 1 — Основные характеристики столбцов

| Название переменной | Описание                                                                               | Единица измерения | Роль в анализе                    |
|---------------------|----------------------------------------------------------------------------------------|-------------------|-----------------------------------|
| Date (Дата)         | Дата проведения измерения                                                              | DD.MM.YYYY        | Временная метка                   |
| Time (Время)        | Время проведения измерения                                                             | HH.MM.SS          | Временная метка                   |
| CO(GT)              | Истинная концентрация оксида углерода (CO)                                             | мг/м <sup>3</sup> | Прекурсор, фактор                 |
| PT08.S1(CO)         | Сопротивление сенсора Tin Oxide (SnO <sub>2</sub> ) для CO. Чувствителен к озону.      | Ом                | Целевой показатель / Фактор       |
| NMHC(GT)            | Концентрация несметанных общих углеводородов                                           | мг/м <sup>3</sup> | Прекурсор, фактор                 |
| C6H6(GT)            | Истинная концентрация бензола                                                          | мг/м <sup>3</sup> | Прекурсор, фактор                 |
| PT08.S2(NMHC)       | Сопротивление сенсора Titanium Dioxide (TiO <sub>2</sub> ) для NMHC                    | Ом                | Фактор                            |
| NOx(GT)             | Истинная концентрация оксидов азота (NOx)                                              | ppb               | Ключевой прекурсор озона, фактор  |
| PT08.S3(NOx)        | Сопротивление сенсора Tungsten Oxide (WO <sub>3</sub> ) для NOx                        | Ом                | Фактор                            |
| NO2(GT)             | Истинная концентрация диоксида азота (NO <sub>2</sub> )                                | µg/m <sup>3</sup> | Ключевой прекурсор озона, фактор  |
| PT08.S4(NO2)        | Сопротивление сенсора Titanium Dioxide (TiO <sub>2</sub> ) для NO <sub>2</sub>         | Ом                | Фактор                            |
| PT08.S5(O3)         | Сопротивление сенсора Molybdenum Oxide (MoS <sub>2</sub> ) для озона (O <sub>3</sub> ) | Ом                | Основной целевой показатель       |
| T (Температура)     | Температура воздуха                                                                    | °C                | Ключевой метеорологический фактор |
| RH (Влажность)      | Относительная влажность                                                                | %                 | Ключевой метеорологический фактор |
| AH (Абс. влажность) | Абсолютная влажность                                                                   | г/м <sup>3</sup>  | Ключевой метеорологический фактор |

Для предварительного анализа целевой переменной PT08.S5(O3) рассчитываются классические статистические параметры: количество наблюдений, количество пропусков, минимальное и максимальное значения,

выборочное среднее, медиана, мода, дисперсия, среднеквадратическое отклонение, коэффициент вариации, асимметрия и эксцесс.

*Листинг 1 — Расчёт метрик для целевой переменной*

```
df = pd.read_csv('AirQualityUCI.csv', sep=';')
col = df['PT08.S5(O3)'].replace(-200, np.nan)

missing = col.isna().sum()
total = len(col)
min_val = col.min()
max_val = col.max()
mean = col.mean()
median = col.median()
mode = col.mode()[0] if not col.mode().empty else np.nan
variance = col.var()
std = col.std()
cv = (std / mean) * 100 if mean != 0 else np.nan
skew = col.skew()
kurt = col.kurt()

print(f'Общее количество: {total}')
print(f'Пропуски: {missing}')
print(f'Мин: {min_val:.2f}')
print(f'Макс: {max_val:.2f}')
print(f'Среднее: {mean:.2f}')
print(f'Медиана: {median:.2f}')
print(f'Мода: {mode:.2f}')
print(f'Дисперсия: {variance:.2f}')
print(f'Стд: {std:.2f}')
print(f'CV (%): {cv:.2f}')
print(f'Асимметрия: {skew:.2f}')
print(f'Эксцесс: {kurt:.2f}')
```

Предварительный анализ целевой переменной PT08.S5(O3) показал, что общий объём наблюдений составляет 9471 запись, из которых 480 (около 5%) являются пропущенными значениями. Диапазон значений переменной варьируется от 221 до 2523 Ом, что указывает на значительную изменчивость концентрации озона в приземном слое атмосферы. Среднее значение (1022.91 Ом) немного выше медианы (963 Ом), что вместе с положительным коэффициентом асимметрии (0.63) свидетельствует о лёгкой правосторонней асимметрии распределения. Наиболее часто встречающееся значение (мода) составляет 825 Ом, что находится ниже среднего, указывая на наличие относительно большого числа периодов с низкой концентрацией озона. Высокое стандартное отклонение (398.48 Ом) и коэффициент вариации (38.96%) подтверждают значительный разброс данных относительно среднего. Значение эксцесса (0.08) близко к нулю, что говорит о распределении с



умеренной «плоскостью», близкой к нормальному. В целом, данные характеризуются выраженной изменчивостью и легкой асимметрией, что требует применения статистических методов для выявления закономерностей и влияния факторов на уровень озона

Для более детального изучения распределения значений сопротивления сенсора PT08.S5(O3) строится вариационный ряд — упорядоченная последовательность значений переменной по возрастанию с указанием абсолютных и относительных частот. Код, представленный на Листинге 2 строит вариационный ряд.

*Листинг 2 — Построение вариационного ряда*

```
col_rounded = col.dropna().round(0)
freq_table = col_rounded.value_counts().sort_index().reset_index()
freq_table.columns = ['Значение (PT08.S5(O3))', 'Абсолютная частота']
n = len(col_rounded)
freq_table['Относительная частота'] = (freq_table['Абсолютная частота'] /
n).round(4)

print("Первые 5 значений вариационного ряда:")
print(freq_table.head(5))
print("\nПоследние 5 значений вариационного ряда:")
print(freq_table.tail(5))
print(f"\nОбщее количество наблюдений: {n}")
```

По итогам работы кода получится заполнить Таблицу 2.

*Таблица 2 — Вариационный ряд для целевой переменной*

| Значений переменной | Абсолютная частота | Относительная частота |
|---------------------|--------------------|-----------------------|
| 221.0               | 1                  | 0.0001                |
| 225.0               | 1                  | 0.0001                |
| 227.0               | 1                  | 0.0001                |
| 232.0               | 1                  | 0.0001                |
| 252.0               | 1                  | 0.0001                |
| ...                 | ...                | ...                   |
| 2494.0              | 1                  | 0.0001                |
| 2515.0              | 1                  | 0.0001                |
| 2519.0              | 1                  | 0.0001                |
| 2522.0              | 1                  | 0.0001                |
| 2523.0              | 1                  | 0.0001                |

Минимальное значение сопротивления составляет 221 Ом, а максимальное — 2523 Ом, что отражает широкий разброс концентраций озона. Наиболее часто встречается значение около 825 Ом, что соответствует

умеренным уровням концентрации озона. Относительные частоты показывают, что большая часть наблюдений сосредоточена в диапазоне 800–1200 Ом, что соответствует типичному уровню загрязнения воздуха на данной станции.

Для визуализации распределения данных строится гистограмма относительных частот. Число групп определяется по правилу Стёрджеса:

$$g = 1 + 3,322 \cdot \log_{10} n, \quad (1.1)$$

где  $n$  — объем выборки.

а ширина интервала рассчитывается как:

$$h = \frac{\max(X) - \min(X)}{g}, \quad (1.2)$$

где  $g$  — число групп;

$X$  — выборка.


Код, реализующий вышеприведенные формулы представлен на Листинге 3.

*Листинг 3 — Построение гистограммы относительных частот*

```
k = int(1 + 3.322 * np.log10(n))
x_min = col_rounded.min()
x_max = col_rounded.max()
h = (x_max - x_min) / k

plt.figure(figsize=(10,5))
plt.hist(col_rounded, bins=k, density=True, color='skyblue',
edgecolor='black')
plt.title('Гистограмма относительных частот PT08.S5(O3)')
plt.xlabel('Сопротивление сенсора, Ом')
plt.ylabel('Относительная частота')
plt.grid(True)
plt.show()
```

Гистограмма, которая получилась в результате работы кода представлена на Рисунке 1.



**Рисунок 1 — Относительные частоты сопротивления сенсора**

Гистограмма демонстрирует, что распределение PT08.S5(O3) имеет основной пик в диапазоне 800–1200 Ом, что соответствует среднему уровню концентрации озона. При этом наблюдается правосторонний «хвост» в диапазоне выше 1500 Ом, что отражает редкие периоды высоких концентраций озона. Такое распределение указывает на неоднородность концентраций озона во времени и необходимость применения статистических методов для анализа влияния прекурсоров и метеорологических факторов.

ЭФР позволяет оценить накопленную частоту наблюдений и наглядно показать, какие значения сопротивления сенсора встречаются чаще всего, без предположений о теоретическом распределении данных.

Эмпирическая функция распределения рассчитывается по Формуле 1.3:

$$F_n(x) = \frac{x_i \leq x}{n} = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x), \quad (1.3)$$

где  $F_n(x)$  — значение эмпирической функции распределения в точке  $x$ ;

$n$  — общее число наблюдений в выборке;

$x_i$  —  $i$ -е наблюдение признака.


Код, рассчитывающий ЭФР и визуализирующий ее представлен на Листинге 4.

*Листинг 4 — Построение эмпирической функции распределения*

```
sorted_col = np.sort(col.dropna())
n = len(sorted_col)
F_n = np.arange(1, n+1) / n

plt.figure(figsize=(10,5))
plt.step(sorted_col, F_n, where='post', color='darkblue')
plt.title('Эмпирическая функция распределения PT08.S5(O3)')
plt.xlabel('Сопротивление сенсора, Ом')
plt.ylabel('F_n(x)')
plt.grid(True)
plt.show()
```

Полученный график представлен на Рисунке 2.



**Рисунок 2 — Эмпирическая функция распределения**

Эмпирическая функция распределения показывает, что большинство наблюдений сосредоточено в диапазоне 800–1200 Ом, что соответствует типичному уровню концентрации озона на исследуемой станции. Значения ниже 500 Ом встречаются редко, что указывает на ограниченное число периодов с низкими концентрациями. Правосторонний «хвост» ЭФР, начиная примерно с 1500 Ом, отражает редкие, но значительные всплески концентрации озона. Такая форма ЭФР подтверждает выводы, полученные при анализе гистограммы и вариационного ряда: распределение

имеет умеренно выраженную правостороннюю асимметрию и высокий разброс значений, что необходимо учитывать при последующем статистическом и регрессионном анализе факторов, влияющих на уровень озона.

Для данных рассчитаем основные параметры. Выборочное среднее является одной из ключевых характеристик распределения данных и отражает центральную тенденцию. Оно показывает типичное значение признака в выборке и рассчитывается по формуле 1.4:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad (1.4)$$

где  $n$  — размер выборки;

$x_i$  —  $i$ -е наблюдение (доля городского населения).

Код, рассчитывающий выборочное среднее представлен на Листинге 5.

*Листинг 5 — Расчёт выборочного среднего*

```
mean = col.mean()  
print(f"Выборочное среднее: {mean:.2f}")
```

Результат расчёта показал, что выборочное среднее сопротивления сенсора составляет 1022.91 Ом. Это значение отражает типичный уровень сопротивления в исследуемой выборке и позволяет судить о характерных показателях сенсора в рассматриваемый период. Среднее значение также даёт отправную точку для оценки разброса данных и дальнейших статистических анализов.

Выборочная дисперсия является мерой разброса данных относительно среднего значения. Она позволяет оценить, насколько сильно значения признака отклоняются от типичного значения и вычисляется по формуле 1.5:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad (1.5)$$

где  $\bar{x}$  — выборочное среднее;

$x_i$  —  $i$ -е наблюдение;

$n$  — размер выборки.

Код, рассчитывающий выборочную дисперсию представлен на Листинге 6.

*Листинг 6 — Расчёт выборочной дисперсии*

```
variance = col.var()  
print(f"Выборочная дисперсия: {variance:.2f}")
```

для сенсора PT08.S5(O3) расчёт показал, что выборочная дисперсия равна 158789.73 Ом<sup>2</sup>. Такое значение указывает на значительный разброс показаний сенсора: некоторые измерения сильно отличаются от среднего, что может быть связано с колебаниями концентрации озона, влиянием внешних факторов или шумами датчика. Высокая дисперсия подчёркивает необходимость учитывать вариативность данных при дальнейших статистических анализах и построении моделей прогнозирования.

Выборочное стандартное отклонение показывает среднее отклонение значений от их среднего. Оно измеряет разброс в тех же единицах, что и сам признак, и вычисляется по формуле 1.6:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}. \quad (1.6)$$

Код, рассчитывающий выборочное стандартное отклонение представлен на Листинге 7.

*Листинг 7 — Расчёт стандартного отклонения*

```
std = col.std()  
print(f"Выборочное среднеквадратическое отклонение: {std:.2f}")
```

Для нашего набора данных выборочное стандартное отклонение

составляет 398.48 Ом, что отражает средний разброс показаний сенсора относительно среднего значения (1022.91 Ом). Высокое стандартное отклонение указывает на значительную изменчивость измерений, что может быть связано с колебаниями концентрации озона или внешними факторами, влияющими на работу датчика. Это подчёркивает важность учета дисперсии при последующем анализе и моделировании.

Коэффициент вариации (CV) позволяет оценить относительный разброс данных относительно среднего значения и выражается в процентах по Формуле 1.7:

$$CV = \frac{s}{\bar{x}} \times 100\%, \quad (1.7)$$

где  $s$  — выборочное стандартное отклонение;

$\bar{x}$  — выборочное среднее.

В нашем случае CV составляет 38.96%, что значительно выше порогового значения 30%, указывающего на умеренный разброс. Это свидетельствует о высокой вариабельности показаний сенсора PT08.S5(O3) и значительной неоднородности данных. Другими словами, наблюдения существенно колеблются относительно среднего значения, что важно учитывать при построении моделей и интерпретации результатов.

Метод максимального правдоподобия (ММП) позволяет оценить параметры распределения концентрации озона, выбирая такие значения среднего и дисперсии, при которых наблюдаемые данные наиболее вероятны. ММП обеспечивает оценки с хорошими свойствами: несмещённость, состоятельность, эффективность и асимптотическую нормальность при больших выборках.

Для концентрации озона предполагаем нормальное распределение функция правдоподобия имеет вид (Формула 1.8):

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)}. \quad (1.8)$$

Для удобства вычислений используется логарифм функции правдоподобия (Формула 1.9):

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (1.9)$$

А для того, чтобы найти оценки параметров, необходимо приравнять частные производные по параметрам и решить систему (Формула 1.10):

$$\begin{cases} \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2 \end{cases}. \quad (1.10)$$

Код, находящий оценки параметров представлен на Листинге 8.

*Листинг 8 — Расчёт оценки параметров*

```
mu_mle = np.mean(col)
sigma2_mle = np.mean((col - mu_mle)**2)

print(f"Оценка параметра μ (метод ММП): {mu_mle:.2f}")
print(f"Оценка параметра σ² (метод ММП): {sigma2_mle:.2f}")
```

Оценка среднего ( $\mu = 1022.91$ ) показывает, что типичная концентрация озона в выборке составляет примерно 1023 единицы (или соответствующую измеряемую величину). Это значение отражает средний уровень озона в наблюдаемых точках.

Оценка дисперсии ( $\sigma^2 = 158772.07$ ) указывает на значительный разброс данных. Высокая дисперсия свидетельствует о том, что концентрации озона сильно различаются между наблюдениями — есть как участки с относительно низким уровнем, так и с очень высоким.

В целом, данные характеризуются умеренным средним значением и высокой вариативностью, что важно учитывать при дальнейшем анализе, прогнозировании и построении моделей.



Свойства оценок методом максимального правдоподобия имеет следующие свойства:

- Несмещённость. оценки среднего и дисперсии отражают истинные параметры генеральной совокупности, так как выборка достаточно велика.
- Состоятельность. при увеличении объёма данных оценки ММП будут всё точнее приближаться к реальным значениям концентрации озона.
- Эффективность. полученные оценки обладают минимально возможной дисперсией среди всех несмещённых оценок, что делает их оптимальными для анализа.
- Асимптотическая нормальность. распределение оценок близко к нормальному, что позволяет применять стандартные методы построения доверительных интервалов и проверки гипотез.

Метод моментов (ММ) — один из классических подходов к оценке параметров распределения, основанный на приравнении теоретических моментов распределения к соответствующим выборочным моментам, вычисленным по данным. Идея метода заключается в том, что параметры модели подбираются так, чтобы значения моментов (например, математического ожидания и дисперсии) совпадали в выборке и теории.

Для нормального распределения теоретические моменты совпадают с параметрами распределения, для выборочных параметров система выглядит следующим образом (Формула 1.11):

$$\begin{cases} m_1 = \frac{1}{n} \sum_{i=1}^n x_i \\ m_2 = \frac{1}{n} \sum_{i=1}^n (x_i - m_1)^2 \end{cases} \quad (1.11)$$

И метод оценки будет иметь вид (Формула 1.12):

$$\begin{cases} \hat{\mu} = m_1 = \bar{x} \\ \widehat{\sigma^2} = m_2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases} \quad (1.12)$$

Код, рассчитывающий параметры методом моментов представлен на Листинге 9.

*Листинг 9 — Расчёт методом моментов*

```
mu_mm = np.mean(col)
sigma2_mm = np.var(col, ddof=1)
print(f"Оценка параметра  $\mu$  (метод моментов): {mu_mm:.2f}")
print(f"Оценка параметра  $\sigma^2$  (метод моментов): {sigma2_mm:.2f}")
```

При использовании метода моментов для оценки параметров распределения концентрации озона получены следующие показатели: среднее значение  $\mu \approx 1022.91$  и дисперсия  $\sigma^2 \approx 158772.07$ . Эти результаты полностью совпадают с оценками, полученными методом максимального правдоподобия, что подтверждает корректность и надежность вычислений.

Среднее значение отражает типичное значение концентрации озона в выборке, а высокая дисперсия указывает на значительное разнообразие наблюдений: от низких до высоких концентраций.

Свойства оценок методом моментов для данной выборки можно охарактеризовать следующим образом:

- Несмещённость. Использование деления на  $n-1$  при расчёте дисперсии обеспечивает её несмещённость, а среднее значение также даёт корректную оценку математического ожидания генеральной совокупности.
- Состоятельность. С увеличением объёма выборки оценки стремятся к истинным параметрам распределения, что позволяет считать их надежными для большого количества наблюдений.
- Эффективность. Метод моментов обеспечивает оценки, близкие по свойствам к ММП, хотя в теории имеет немного большую

дисперсию; на практике при больших выборках это влияние минимально.

- Асимптотическая нормальность. При достаточно больших объемах выборки распределение оценок приближается к нормальному, что позволяет применять стандартные статистические методы, включая построение доверительных интервалов и проверку гипотез.

Таким образом, метод моментов для данных по озону показал стабильные и интерпретируемые результаты, адекватно отражающие уровень и вариабельность концентрации озона в выборке.

Байесовский подход заключается в том, чтобы начать с предположений о параметрах в виде априорного распределения и затем обновлять эти предположения с учётом наблюдаемых данных. В итоге формируется апостериорное распределение, из которого можно извлечь оценки интересующих параметров, например, их среднее значение. Главная идея метода заключается в Формуле 1.13:

$$p(x|\theta) = \frac{p(x|\theta)p(\theta)}{p(x)}, \quad (1.13)$$

где  $p(\theta)$  — априорное распределение параметра;

$p(x|\theta)$  — функция правдоподобия;

$p(\theta|x)$  — апостериорное распределение (обновлённое знание о параметре после наблюдения данных).

Рассмотрим нормальное распределение и зададим слабо информативные априорные распределения (что часто используется в практическом анализе при отсутствии априорных знаний). В таком случае Байесовская оценка параметра равна (Формула 1.14):

$$\hat{\mu} = E(\mu|x) = \bar{x}. \quad (1.14)$$

Для дисперсии при неинформативном априоре используется аналогичный результат (Формула 1.15):

$$E(\sigma^2|x) = \frac{(n-1)s^2}{(n-3)}, \quad (1.15)$$

где  $s^2$  — выборочная дисперсия.

Код для вычисления Байесовской оценки распределения представлен на Листинге 10.

*Листинг 10 — Расчёт методом Байеса*

```
x_mean = np.mean(col)
s2 = np.var(col, ddof=1)
mu_bayes = x_mean
sigma2_bayes = ((n - 1) * s2) / (n - 3)
print(f"Байесовская оценка параметра  $\mu$ : {mu_bayes:.2f}")
print(f"Байесовская оценка параметра  $\sigma^2$ : {sigma2_bayes:.2f}")
```

Для ваших данных Байесовские оценки параметров составили: среднее значение  $\mu = 1022.91$  и дисперсия  $\sigma^2 = 158823.27$ . Эти результаты практически совпадают с оценками, полученными методами максимального правдоподобия и моментов, что свидетельствует о согласованности и надёжности применённых подходов.

Характерные свойства Байесовских оценок для этих данных:

- Несмещённость: при использовании неинформативного априорного распределения оценка среднего совпадает с выборочным средним, а смещение оценки дисперсии невелико и практически исчезает при большом объёме выборки.
- Состоятельность: по мере увеличения числа наблюдений оценки сходятся к истинным значениям параметров, что делает их надёжными.
- Эффективность: при большом объёме данных оценка среднего практически идентична ММП и обладает близкой к оптимальной дисперсией.

- Асимптотическая нормальность: при значительном размере выборки апостериорное распределение среднего приблизительно нормальное, что позволяет использовать стандартные методы для доверительных интервалов и проверки гипотез.

Полученные оценки для методов точечной оценки параметром представлены в Таблице 3.

Таблица 3 — Оценки параметров

| Метод                                   | Оценка параметра $\mu$ | Оценка параметра $\sigma^2$ |
|-----------------------------------------|------------------------|-----------------------------|
| Метод максимального правдоподобия (ММП) | 1022.91                | 158772.07                   |
| Метод моментов (ММ)                     | 1022.91                | 158772.07                   |
| Байесовская оценка                      | 1022.91                | 158823.27                   |

Проведённый предварительный анализ данных по концентрации озона показал, что выборка обладает хорошим качеством: пропуски составляют около 5,07%. Значения показателя колеблются от 221.00 до 2523.00, что отражает значительную неоднородность концентрации озона в разных наблюдаемых точках. Среднее значение (1022.91) и медиана (963.00) демонстрируют умеренный уровень содержания озона, тогда как высокая дисперсия и коэффициент вариации (38.96%) указывают на широкий разброс данных.

Построение вариационного ряда с абсолютными и относительными частотами, а также ступенчатой эмпирической функции распределения позволило наглядно оценить распределение значений и накопление частоты. Эти результаты подтверждают разнообразие уровней концентрации озона и создают основу для дальнейшего статистического анализа.

Применение трёх методов точечных оценок — максимального правдоподобия, моментов и Байесовского — показало практически полное совпадение результатов ( $\mu \approx 1022.91$ ,  $\sigma^2 \approx 158772\text{--}158823$ ), что свидетельствует о стабильности оценок и корректности модели. Все оценки обладают свойствами несмещённости, состоятельности, эффективности и асимптотической нормальности.

Таким образом, исследуемые данные характеризуются широким диапазоном значений, значительной вариативностью и умеренным средним уровнем концентрации озона, что делает их пригодными для дальнейшего анализа динамики озона, выявления зависимостей с другими атмосферными параметрами и построения прогнозных моделей.

## **1.2 Анализ вспомогательного признака**

Исследование концентрации озона невозможно без учёта факторов, которые способны изменять её уровень. Одним из таких факторов выступает температура воздуха, оказывающая значительное влияние на скорость фотохимических реакций в атмосфере. При высоких температурах эти реакции протекают интенсивнее, что способствует увеличению концентрации озона, тогда как при низких температурах активность процессов уменьшается. Таким образом, температурный режим можно рассматривать как один из ключевых климатических показателей, связанных с динамикой содержания озона.

Прежде чем переходить к более сложным методам анализа, была проведена оценка распределения температурных данных. Для этого значения температуры были предварительно преобразованы логарифмически, чтобы уменьшить влияние экстремальных наблюдений и сделать распределение более сбалансированным. Далее был составлен вариационный ряд, включающий абсолютные и относительные частоты появления значений. Такой подход позволяет понять, в каких интервалах температур сосредоточено наибольшее количество наблюдений и каков общий характер распределения.

Построение вариационного ряда показано на Листинге 11.

#### Листинг 11 — Построение вариационного ряда

```
df = pd.read_csv('AirQualityUCI.csv', sep=';')
df['T'] = df['T'].astype(str).str.replace(',', '.')
df['T'] = pd.to_numeric(df['T'], errors='coerce')
col = df['T'].dropna()
col_log = np.log1p(col)
n = len(col_log)
col_rounded = col_log.round(2)
freq_table = col_rounded.value_counts().sort_index().reset_index(
freq_table.columns = ['Значение log(T)', 'Абсолютная частота']
freq_table['Относительная частота'] = freq_table['Абсолютная частота'] / n
print("Первые 5 значений вариационного ряда после логарифмирования:")
print(freq_table.head(5))
print("\nПоследние 5 значений вариационного ряда после логарифмирования:")
print(freq_table.tail(5))
```

На основе полученных данных построим Таблицу 4.

Таблица 4 — Вариационный ряд для температуры

| Значение | Абсолютная частота | Относительная частота |
|----------|--------------------|-----------------------|
| -0.92    | 2                  | 0.000214              |
| -0.69    | 1                  | 0.000107              |
| -0.36    | 1                  | 0.000107              |
| -0.22    | 1                  | 0.000107              |
| -0.11    | 2                  | 0.000214              |
| ...      | ...                | ...                   |
| 3.77     | 3                  | 0.000321              |
| 3.78     | 5                  | 0.000534              |
| 3.79     | 2                  | 0.000214              |
| 3.81     | 1                  | 0.000107              |
| 3.82     | 1                  | 0.000107              |

Начальные элементы вариационного ряда после логарифмирования демонстрируют, что значения температуры преимущественно сосредоточены в низком диапазоне — это отражает преобладание умеренных температурных условий в выборке. Абсолютные и относительные частоты для этих наблюдений невелики, что говорит о равномерном распределении данных без выраженных пиков.

Верхняя часть ряда, напротив, характеризуется редкими случаями высоких температур, встречающихся крайне редко. Небольшие значения относительных частот указывают на то, что такие наблюдения представляют собой скорее исключения, чем типичные условия.

Применение логарифмирования позволило сгладить разброс данных и уменьшить влияние экстремальных значений. В результате распределение стало более сбалансированным и удобным для дальнейшего анализа, включая


изучение взаимосвязей температуры с другими параметрами, такими как концентрация загрязняющих веществ.

Количество интервалов для построения гистограммы было определено по формуле Стёрджеса (1.1), что обеспечивает оптимальный баланс между детализацией и обобщением данных. Такой подход позволяет наглядно представить распределение температурных значений и выявить основные закономерности в их вариации. Код, реализующий построение гистограммы, приведён на Листинге 12.

*Листинг 12 — Построение гистограммы*

```
k = int(np.ceil(1 + 3.322 * np.log10(n)))
plt.figure(figsize=(8,4))
plt.hist(col_log, bins=k, density=True, color='skyblue', edgecolor='black',
alpha=0.7)
plt.title('Гистограмма логарифмированных значений температуры')
plt.xlabel('log(T + 1)')
plt.ylabel('Относительная частота')
plt.grid(True)
plt.show()
```

Получившаяся диаграмма представлена на Рисунке 3.



**Рисунок 3 — Гистограмма логарифмированных значений температуры**

Гистограмма логарифмированных значений температуры демонстрирует форму, близкую к нормальному распределению, с выраженным



максимумом в диапазоне 2,5–3,5. Это говорит о том, что большинство наблюдений приходится на умеренные температурные значения. Незначительная левосторонняя асимметрия указывает на присутствие отдельных периодов с пониженной температурой, которые встречаются сравнительно редко.

Применение логарифмирования позволило скорректировать влияние выбросов и сделать распределение более симметричным. Такая нормализация данных обеспечивает корректность последующих статистических расчётов — например, оценок среднего и дисперсии — и создаёт основу для анализа взаимосвязей температуры с концентрацией озона и другими факторами.


Эмпирическая функция распределения (1.3) используется для визуального анализа накопления частоты значений температуры и позволяет оценить, как изменяется доля наблюдений в зависимости от уровня показателя. Для каждого значения функция показывает вероятность того, что температура не превышает заданный порог. Такой подход особенно полезен при анализе данных после логарифмического преобразования, поскольку помогает выявить концентрацию наблюдений в определённых диапазонах и оценить характер распределения. Реализация ЭФР представлена на Листинге 13.

*Листинг 13 — Расчёт эмпирической функции*

```
x_values_cdf = np.sort(col_log)
y_values_cdf = np.arange(1, n+1) / n

plt.figure(figsize=(8,4))
plt.step(x_values_cdf, y_values_cdf, where='post', color='orange')
plt.title('Эмпирическая функция распределения логарифмированной плотности населения')
plt.xlabel('log(T + 1)')
plt.ylabel('F_n(x)')
plt.grid(True)
plt.show()
```

Получившаяся эмпирическая функция распределений представлена на Рисунке 4.



**Рисунок 4 — Эмпирическая функция логарифмированных значений температуры**

ЭФР логарифмированных значений температуры показывает, что основная часть наблюдений сосредоточена в диапазоне 3–4, что отражает преобладание умеренных температур в выборке. Значительно меньшая часть значений приходится на низкие температуры, тогда как высокие температуры встречаются редко и представляют собой экстремальные случаи. Такая структура распределения позволяет сделать вывод о том, что температура в наблюдаемом периоде в большинстве случаев находится в умеренном диапазоне, а редкие отклонения могут оказывать влияние на концентрацию озона.

Для начала оценим основные статистические параметры логарифмированных значений концентрации озона. Выборочное среднее отражает центральное положение данных и показывает типичный уровень концентрации в выборке. Его расчет представлен на Листинге 14.

*Листинг 14 — Расчёт выборочного среднего*

```
mean_T = col_log.mean()  
print(f"Выборочное среднее логарифмированной температуры: {mean_T:.2f}")
```

Среднее значение, равное примерно 2.83, указывает на характерную температуру в большинстве наблюдений. Большая часть данных сосредоточена вокруг этого уровня, что позволяет говорить о типичной интенсивности показателя в исследуемый период.

Выборочная дисперсия характеризует, насколько значения отклоняются от среднего и насколько сильно различаются между наблюдениями. Реализация расчёта приведена на Листинге 15.

*Листинг 15 — Расчёт выборочной дисперсии*

```
var_log_T = col_log.var(ddof=1)
print(f"Выборочная дисперсия логарифмированной температуры: {var_log_T:.2f}")
```

Дисперсия, равная примерно 0.31, показывает умеренный разброс значений. Это отражает наличие как низких, так и относительно высоких температур, но при этом экстремальные значения после логарифмирования не оказывают чрезмерного влияния на анализ.

Среднеквадратическое отклонение (СКО), являющееся квадратным корнем из дисперсии, даёт представление о среднем отклонении значений от среднего уровня. Расчёт представлен на Листинге 16.

*Листинг 16 — Расчёт СКО*

```
std_log_T = col_log.std(ddof=1)
print(f"Выборочное стандартное отклонение логарифмированной температуры: {std_log_T:.2f}")
```

СКО, равное примерно 0.56, подтверждает умеренный разброс данных, что делает распределение после логарифмирования более равномерным и пригодным для последующего статистического анализа.

Коэффициент вариации (CV) выражает относительную изменчивость данных, показывая степень отклонения значений относительно среднего. Его расчет показан на Листинге 17.

*Листинг 17 — Расчёт коэффициента вариации*

```
cv_log_T = (std_log_T / mean_log_T) * 100
print(f"Коэффициент вариации логарифмированной температуры: {cv_log_T:.2f}%")
```

Относительная изменчивость, равная примерно 19.69%, свидетельствует о том, что после логарифмирования температуры оказывают умеренное влияние на общую картину.

Таким образом, логарифмированные значения температуры демонстрируют умеренный средний уровень и стабильный разброс, что позволяет корректно использовать их для дальнейших статистических оценок, построения корреляций и анализа тенденций.

**Метод максимального правдоподобия (ММП)** используется для получения точечных оценок параметров распределения, которые делают имеющиеся наблюдения максимально вероятными. В нашем случае анализ проводится для логарифмированных значений концентрации озона, для которых оцениваются два ключевых параметра: среднее (математическое ожидание) и дисперсия. Программная реализация ММП представлена на Листинге 18.

*Листинг 18 — Реализация ММП*

```
mu_mle = col_log.mean()
sigma2_mle = col_log.var(ddof=0)
print(f"Оценка параметра  $\mu$  (ММП): {mu_mle:.2f}")
print(f"Оценка параметра  $\sigma^2$  (ММП): {sigma2_mle:.2f}")
```

Среднее значение, рассчитанное методом ММП, составляет 2.83, что совпадает с выборочным средним. Это подтверждает несмещённость оценки и корректно отражает центральную тенденцию логарифмированных значений температуры.

Дисперсия, равная около 0.31, демонстрирует умеренный разброс значений. Она позволяет количественно оценить вариативность температур после логарифмирования и указывает на то, что большинство наблюдений сосредоточено относительно среднего уровня.

Основные свойства оценок методом максимального правдоподобия:

- Несмещённость — оценки совпадают с выборочными характеристиками и не имеют систематической ошибки;
- Состоятельность — при увеличении объёма данных оценки стремятся к истинным параметрам распределения;
- Эффективность — среди всех несмещённых оценок ММП минимизирует дисперсию, что делает полученные значения наиболее точными для текущей выборки;
- Асимптотическая нормальность — при больших  $n$  распределение оценок приближается к нормальному, что позволяет использовать

стандартные методы построения доверительных интервалов и проверки гипотез.

Метод моментов (ММ) базируется на приравнивании теоретических моментов распределения к соответствующим выборочным моментам данных. Для аппроксимации логарифмированной температуры удобно использовать нормальное распределение, при этом оцениваются два основных параметра: среднее значение (первый момент) и дисперсия (второй центральный момент). Программная реализация метода моментов представлена на Листинге 19.

*Листинг 19 — Реализация метода моментов*

```
mu_mom = col_log.mean()
sigma2_mom = col_log.var(ddof=1)
print(f"Оценка параметра  $\mu$  (метод моментов): {mu_mom:.2f}")
print(f"Оценка параметра  $\sigma^2$  (метод моментов): {sigma2_mom:.2f}")
```

Среднее значение логарифмированной температуры, полученное методом моментов, составляет 2.83, что совпадает с выборочным средним и с оценкой ММП. Это подтверждает несмещённость оценки и адекватность отражения центральной тенденции данных.

Дисперсия, рассчитанная методом моментов, равна 0.31, что близко к оценке ММП с делением на  $n$ . Она отражает умеренный разброс логарифмированных значений температуры и позволяет количественно оценить вариативность данных.

Основные свойства оценок методом моментов:

- Несмещённость — полученные значения  $\mu$  и  $\sigma^2$  адекватно представляют истинные параметры распределения;
- Состоятельность — при увеличении объёма выборки оценки стремятся к истинным значениям;
- Эффективность — оценки достаточно точны, хотя для небольших выборок метод моментов может уступать ММП;
- Асимптотическая нормальность — при больших  $n$  распределение оценок приближается к нормальному, что позволяет применять

стандартные методы проверки гипотез и построения доверительных интервалов.

Байесовский подход опирается на использование априорной информации о параметрах распределения для уточнения оценок после анализа данных. В случае логарифмированной концентрации озона применён неинформативный априор, что при достаточно большой выборке даёт оценки, близкие к классическим методам (ММП и метод моментов). Такой подход позволяет получать более устойчивые результаты, особенно при ограниченных или асимметричных данных. Программная реализация вышеописанного подхода представлена на Листинге 20.

*Листинг 20 — Расчёт методом Байеса*

```
mu_bayes = col_log.mean()
sigma2_bayes = col_log.var(ddof=1)

print(f"Байесовская оценка параметра  $\mu$ : {mu_bayes:.2f}")
print(f"Байесовская оценка параметра  $\sigma^2$ : {sigma2_bayes:.2f}")
```

Вычисленные значения для логарифмированной температуры:

$\mu = 2.83$  — совпадает с выборочным средним и оценками ММП и методом моментов, что подтверждает несмещённость оценки и её адекватное отражение центральной тенденции данных;

$\sigma^2 = 0.31$  — также близка к другим оценкам дисперсии, показывая умеренный разброс значений логарифмированных температур.

Свойства Байесовских оценок:

- Несмещённость — оценки отражают истинные параметры распределения без систематической ошибки;
- Состоятельность — при увеличении объёма выборки оценки сходятся к истинным значениям параметров;
- Эффективность — при больших выборках Байесовские оценки среднего и дисперсии практически идентичны ММП и обладают минимальной возможной дисперсией среди несмещённых оценок;
- Асимптотическая нормальность — распределение оценок приближается к нормальному, что позволяет применять

стандартные методы проверки гипотез и построения доверительных интервалов.

Полученные оценки для методов точечной оценки параметром представлены в Таблице 5.

Таблица 5 — Оценки параметров

| Метод                                   | Оценка параметра $\mu$ | Оценка параметра $\sigma^2$ |
|-----------------------------------------|------------------------|-----------------------------|
| Метод максимального правдоподобия (ММП) | 2.83                   | 0.31                        |
| Метод моментов (ММ)                     | 2.83                   | 0.31                        |
| Байесовская оценка                      | 2.83                   | 0.31                        |

Во втором разделе проведён анализ температуры воздуха (Т), выбранной в качестве вспомогательного признака для изучения концентрации озона. Для наглядной оценки распределения значений температуры были построены вариационный ряд с абсолютными и относительными частотами, гистограмма и ступенчатая эмпирическая функция распределения. Анализ показал, что большинство наблюдений сосредоточено в среднем диапазоне температур, тогда как крайне низкие и высокие значения встречаются редко и оказывают минимальное влияние на общую структуру данных.

Расчёт выборочных характеристик показал среднее значение температуры 2.83 и дисперсию 0.31, что отражает умеренную изменчивость данных. Среднеквадратическое отклонение 0.56 и коэффициент вариации около 19.8% подтверждают, что относительная изменчивость температуры невелика и экстремальные значения не искажают общую картину.

Точечные оценки параметров распределения, полученные методами максимального правдоподобия, моментов и Байеса совпадают. Это демонстрирует несмещённость, состоятельность, эффективность и асимптотическую нормальность оценок, подтверждая корректность выбранного подхода к анализу температуры как вспомогательного признака.

Анализ позволяет охарактеризовать распределение температуры как относительно симметричное с небольшой вариативностью, при этом основная масса наблюдений сосредоточена в умеренном диапазоне. Полученные

результаты создают надёжную основу для дальнейшего изучения влияния температуры на концентрацию озона и построения корреляционных моделей.



## 2 ОЦЕНКА ПАРАМЕТРОВ РАСПРЕДЕЛЕНИЯ

### 2.1 Оценка параметров распределения целевой переменной

Для целевой переменной PT08.S5(O3), отражающей сопротивление сенсора, чувствительного к концентрации озона, рассчитаем точечные оценки медианы, моды, математического ожидания, дисперсии и среднеквадратического отклонения. Эти статистические характеристики позволяют дополнить предварительный анализ и более детально описать распределение значений сопротивления.

Медиана представляет собой значение, которое делит упорядоченную выборку на две равные части: половина наблюдений меньше медианы, а половина — больше. Она устойчива к выбросам и не зависит от экстремальных значений, что делает её надёжным показателем центральной тенденции. Расчёт медианы производится по Формуле (2.1):

$$\begin{cases} Me = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, \text{ если } n - \text{чётное} \\ Me = \frac{x_{(\frac{n}{2})}}{2}, \text{ если } n - \text{нечётное} \end{cases}, \quad (2.1)$$

Программный расчет медианы представлен на Листинге 21.

*Листинг 21 — Расчёт медианы*

```
median_value = col.median()  
print(f"Медиана: {median_value:.2f}")
```

Медиана сопротивления сенсора PT08.S5(O3) составляет 963 Ом, что означает, что половина наблюдений имеет значения сопротивления ниже этого уровня, а другая половина — выше. Так как значение медианы находится близко к среднему ( $\approx 1075$  Ом), можно сделать вывод, что распределение данных в целом симметрично, а наличие значений, отклоняющихся от

центральной тенденции, незначительно. Это указывает на стабильность работы сенсора и отсутствие выраженных выбросов в показаниях.

Мода — это наиболее часто встречающееся значение выборки, отражающее пик распределения признака. В отличие от среднего и медианы, мода показывает то значение, которое наблюдается чаще всего, и тем самым характеризует наиболее типичное состояние изучаемого объекта. Для непрерывных данных мода определяется по максимуму плотности распределения, однако на практике вычисляется как значение с наибольшей частотой встречаемости.

Программный расчет моды представлен на Листинге 22.

*Листинг 22 — Расчёт моды*

```
mode_value = col.mode()[0]
print(f"Мода: {mode_value:.2f}")
```

Наиболее часто встречающееся значение сопротивления сенсора PT08.S5(O3) составляет 825 Ом. Это значение отражает наиболее распространённое состояние сенсора, при котором концентрация озона в воздухе находится в типичном диапазоне. Совпадение моды с центральной областью распределения указывает на относительную устойчивость работы сенсора и отсутствие выраженных выбросов. Таким образом, 825 Ом можно считать характерным уровнем сопротивления, при котором сенсор фиксирует средний уровень озона в атмосфере.

Математическое ожидание отражает средний уровень признака в генеральной совокупности и в выборке оценивается через выборочное среднее. Этот показатель показывает центральную тенденцию распределения — то значение, вокруг которого сосредоточены остальные наблюдения, считается по Формуле 2.2:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i. \quad (2.2)$$

Его расчёт представлен на Листинге 23.

*Листинг 23 — Расчёт математического ожидания*

```
mean_value = col.mean()
print(f"Математическое ожидание (среднее): {mean_value:.2f}")
```

Среднее значение сопротивления сенсора PT08.S5(O3) составляет 1022.91 Ом. Этот показатель отражает средний уровень концентрации озона, регистрируемый сенсором в исследуемый период. Сравнение с медианой (963 Ом) и модой (825 Ом) показывает небольшое смещение распределения вправо, что указывает на наличие ряда высоких значений сопротивления. Таким образом, среднее значение 1022.91 Ом характеризует общий уровень работы сенсора PT08.S5(O3) и может использоваться в качестве базового ориентира при анализе динамики загрязнения воздуха озоном.

Дисперсия показывает, насколько значения признака отклоняются от среднего, отражая разброс данных вокруг математического ожидания. Для оценки используется выборочная дисперсия с поправкой на несмещённость, считается по Формуле 2.3:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (2.3)$$

Программный расчёт представлен на Листинге 24.

*Листинг 24 — Расчёт дисперсии*

```
variance_value = col.var()
print(f"Выборочная дисперсия: {variance_value:.2f}")
```

Дисперсия сопротивления сенсора PT08.S5(O3) равна 158789.73 Ом<sup>2</sup>, что указывает на значительный разброс данных. Это отражает разнообразие показаний сенсора в разные часы и дни: встречаются как низкие, так и высокие значения. Высокая дисперсия подчеркивает неоднородность концентрации озона, что важно учитывать при анализе данных и построении прогнозных моделей.

Среднеквадратическое отклонение (СКО) отражает среднее отклонение наблюдений от выборочного среднего и показывает типичный разброс данных. Оно рассчитывается по Формуле 2.4:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}. \quad (2.4)$$

Программный расчет представлен на Листинге 25.

*Листинг 25 — Расчёт дисперсии*

```
std_value = col.std()
print(f"Выборочное стандартное отклонение: {std_value:.2f}")
```

Среднеквадратическое отклонение 398.48 Ом показывает, что значения сопротивления сенсора сильно варьируются вокруг среднего. Это отражает широкий разброс показаний сенсора PT08.S5(O3), что может быть связано с изменениями концентрации озона в разные часы и условия измерения.

Для оценки надёжности точечных характеристик можно построить доверительные интервалы с уровнем доверия  $\gamma = 0.95$ . Предполагается нормальное распределение данных. Доверительный интервал для математического ожидания рассчитывается по Формуле 2.5:

$$\bar{x} - t_{\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}} < \mu < \bar{x} + t_{\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}, \quad (2.5)$$

где  $t_{\frac{\alpha}{2}}$  — квантиль распределения Стьюдента с  $(n - 1)$  степенями свободы,  $\alpha = 1 - \gamma$ .

Для дисперсии будет рассчитана по Формуле 2.6:

$$\frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}}^2} < \sigma^2 < \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}}^2}, \quad (2.6)$$

где  $\chi^2$  — квантили хи-квадрат распределения с  $(n - 1)$  степенями свободы.

Программный расчет доверительных интервалов представлен на Листинге 26.

*Листинг 26 — Расчёт доверительных интервалов*

```
n = len(col.dropna())
mean_value = col.mean()
std_value = col.std(ddof=1)
alpha = 0.05

t_crit = stats.t.ppf(1 - alpha/2, df=n-1)
ci_mean_lower = mean_value - t_crit * (std_value / np.sqrt(n))
ci_mean_upper = mean_value + t_crit * (std_value / np.sqrt(n))
chi2_lower = stats.chi2.ppf(alpha/2, df=n-1)
chi2_upper = stats.chi2.ppf(1 - alpha/2, df=n-1)
var_value = std_value**2
ci_var_lower = (n-1) * var_value / chi2_upper
ci_var_upper = (n-1) * var_value / chi2_lower
```

Доверительный Среднее сопротивление сенсора равно 1022.91 Ом, и доверительный интервал [1014.67, 1031.14] полностью охватывает эту оценку, что подтверждает корректность расчёта.

Дисперсия равна 158,789.73, а доверительный интервал [154,248.08, 163,535.93] также содержит оценку, демонстрируя согласованность результатов. Высокая дисперсия и широкий разброс показаний сенсора отражают значительные колебания концентрации озона в разные часы. Узкие доверительные интервалы относительно объёма выборки указывают на высокую точность оценок.

Критерий Шапиро–Уилка (Shapiro–Wilk test) используется для проверки гипотезы о нормальности распределения данных. Он позволяет определить, соответствует ли эмпирическое распределение выборки теоретическому нормальному распределению. Этот тест является одним из наиболее мощных для проверки нормальности при малых и средних выборках, но при очень больших объёмах данных становится слишком чувствительным даже к незначительным отклонениям.

Для сопротивления сенсора PT08.S5(O3) данный критерий применим, так как позволяет проверить, можно ли считать распределение измеренных значений нормальным. Поскольку сенсор фиксирует концентрацию озона в

воздухе, данные могут иметь выбросы и мультимодальную структуру, что делает тест полезным инструментом для подтверждения или опровержения предположения о нормальности. Тестовая статистика  $W$  вычисляется по Формуле 2.7:

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (2.7)$$

где  $x_{(i)}$  — упорядоченные значения выборки (от наименьшего к наибольшему);

$\bar{x}$  — среднее арифметическое выборки;

$a_i$  — коэффициенты, зависящие от ожидаемых значений и ковариации нормального распределения.

Чем ближе значение  $W$  к 1, тем более данные соответствуют нормальному распределению. Малые значения  $W$  и низкие  $p$ -значения свидетельствуют о нарушении нормальности.

Программная реализация критерий Шапиро–Уилка представлена на Листинге 27.

*Листинг 27 — Программная критерия Шапиро–Уилка*

```
col_full = df['PT08.S5(O3)'].replace(-200, np.nan).dropna()
n_full = len(col_full)

max_n = 5000
if n_full > max_n:
    col = col_full.sample(n=max_n, random_state=42)
    note = f"(подвыборка n={max_n} из {n_full})"
else:
    col = col_full
    note = f"(n={n_full})"

W, p_value = stats.shapiro(col)

print(f"Shapiro-Wilk W = {W:.4f}, p-value = {p_value:.4e} {note}")
```

Результаты применения критерия Шапиро–Уилка к данным сопротивления сенсора PT08.S5(O3) показали, что статистика  $W=0.9714$  и значение  $p\text{-value} = 1.70 \times 10^{-30}$  при уровне значимости  $\alpha=0.05$ . Это значение значительно меньше порогового уровня, что свидетельствует о статистически значимом отклонении распределения от нормального закона.

Критерий Шапиро–Уилка позволил подтвердить, что сопротивление сенсора не следует нормальному распределению, а значит, при дальнейшем статистическом анализе следует отдавать предпочтение непараметрическим или робастным методам, менее чувствительным к форме распределения. Это обеспечивает корректность выводов и устойчивость результатов при анализе вариаций концентрации озона.

Критерий Андерсона–Дарлинга подходит для анализа сопротивления сенсора PT08.S5(O3), так как позволяет более точно оценить степень соответствия эмпирических данных нормальному распределению, уделяя особое внимание отклонениям в хвостах распределения. Это особенно важно для сенсорных данных, где в силу внешних факторов (температуры, влажности, концентрации загрязнителей) часто наблюдаются экстремальные значения. Статистика критерия вычисляется по Формуле (2.8):

$$A^2 = -n - \frac{1}{n} \sum_{i=1}^n (2i - 1) \left[ \ln F(x_{(i)}) + \ln (1 - F(x_{(n+1-i)})) \right] \quad (2.8)$$

где  $n$  — размер выборки;

$F(x_{(i)})$  — теоретическая функция распределения (для нормального распределения — нормальная кумулятивная функция вероятности);

$x_{(i)}$  — упорядоченные наблюдения.

Программная реализация критерия Андерсона–Дарлинга представлена на Листинге 28.

*Листинг 28 — Программная реализация критерия Андерсона–Дарлинга*

```
from scipy import stats
import numpy as np
import pandas as pd

col = df['PT08.S5(O3)'].replace(-200, np.nan).dropna()
result = stats.anderson(col, dist='norm')

A2_stat = round(result.statistic, 4)
crit_values = result.critical_values
sig_levels = result.significance_level

print(f"Anderson-Darling A² = {A2_stat}")
for s, c in zip(sig_levels, crit_values):
    print(f"    Уровень значимости {s}% → критическое значение {c}")
```

Для сопротивления сенсора PT08.S5(O3) байесовский подход подходит. Результаты критерия Андерсона–Дарлинга показали значительное отклонение распределения сопротивления сенсора PT08.S5(O3) от нормального закона. Полученное значение статистики  $A^2=65.868$  многократно превышает все критические значения даже для самого строгого уровня значимости. Это означает, что нулевая гипотеза о нормальности распределения уверенно отвергается.

Такое поведение данных свидетельствует о нелинейности и асимметрии распределения сопротивления сенсора, что типично для физических измерений, зависящих от внешних факторов, таких как температура, влажность и концентрация загрязняющих веществ. Повышенные значения  $A^2$  указывают на наличие длинных хвостов и возможной мультимодальности, что согласуется с результатами, полученными ранее при визуальном анализе и с помощью критерия Шапиро–Уилка.

Таким образом, критерий Андерсона–Дарлинга подтвердил, что выборка не соответствует нормальному распределению, а значит, для дальнейшего анализа данных сенсора целесообразно использовать непараметрические методы или робастные оценки, менее чувствительные к выбросам и асимметрии. Это обеспечивает более корректную интерпретацию поведения сенсора и устойчивость статистических выводов в условиях реальных измерений.

Для данных сопротивления сенсора PT08.S5(O3) применение метода наименьших квадратов (OLS) нецелесообразно. OLS используется для оценки параметров линейной зависимости между зависимой переменной  $y$  и одной или несколькими независимыми переменными  $X$ , что выражается по Формуле 2.9:

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (2.9)$$

где  $\hat{\beta}$  — вектор оценённых коэффициентов;



$X$  — матрица факторов;

$y$  — наблюдаемые значения зависимой переменной.

В контексте текущего исследования данные представляют собой однофакторную выборку измерений сопротивления сенсора и не содержат предикторов (независимых переменных), с которыми можно было бы строить регрессионную модель. Задача состоит не в моделировании зависимости, а в оценке распределения, устойчивости и параметров выборки (среднее, дисперсия, доверительные интервалы).

Применённые методы — критерий Шапиро–Уилка и критерий Андерсона–Дарлинга — обеспечили комплексную проверку характеристик распределения и закономерностей в данных сопротивления сенсора PT08.S5(O3). Нормативные критерии (Шапиро–Уилка и Андерсона–Дарлинга) показали отклонение распределения от нормального закона, что свидетельствует о наличии асимметрии и длинных хвостов, характерных для измерений в реальных условиях окружающей среды. Это подтверждает необходимость использования робастных и непараметрических подходов в дальнейшем анализе.

Следующим шагом анализа является оценка функции распределения (CDF) и функции плотности вероятности (PDF) сопротивления сенсора. Это позволяет перейти от точечных и интервальных оценок к восстановлению вероятностного распределения данных сенсора, что даёт более полное представление о поведении показателя.

Эмпирическая функция распределения — это непараметрическая оценка CDF, построенная непосредственно по выборке. Она показывает долю наблюдений, не превышающих заданное значение  $x$  и рассчитывается по Формуле 2.10:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(x_i \leq x), \quad (2.10)$$

где  $\mathbb{I}$  — индикаторная функция.

Построение и визуализация эмпирической функции распределения представлено на Листинге 29.

*Листинг 29 — Программная реализация построения и визуализации эмпирической функции*


```
df = pd.read_csv('AirQualityUCI.csv', sep=';')

col = df['PT08.S5(O3)'].replace(-200, np.nan).dropna()

ecdf = ECDF(col)

plt.figure(figsize=(10, 6))
plt.step(ecdf.x, ecdf.y, where='post', color='green', linewidth=2)
plt.xlabel('Сопротивление сенсора PT08.S5(O3)')
plt.ylabel('F(x)')
plt.title('Эмпирическая функция распределения (ECDF) сопротивления сенсора')
plt.grid(True, alpha=0.3)
plt.show()
```

Получившийся график представлен на Рисунке 5.



**Рисунок 5 — Эмпирическая функция распределения сопротивления сенсора**

Построение ECDF позволяет наглядно увидеть концентрацию значений сопротивления: нижний хвост демонстрирует редкие низкие значения, основная масса данных сосредоточена в диапазоне около 500–1500.

Гистограмма — простейшая оценка плотности, но чувствительна к выбору числа интервалов. Ядерная оценка плотности (KDE) — сглаженная непараметрическая оценка PDF рассчитывается по Формуле 2.11:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad (2.11)$$

где  $K$  — гауссово ядро;

$h$  — ширина окна

Программная реализация гистограммы представлена на Листинге 30.

*Листинг 30 — Программная реализация гистограммы*

```
plt.figure(figsize=(10, 6))

plt.hist(col, bins=50, density=True, alpha=0.6, color='lightgray',
label='Гистограмма')

kde = gaussian_kde(col)
x_grid = np.linspace(col.min(), col.max(), 1000)
plt.plot(x_grid, kde(x_grid), 'r-', lw=2, label='KDE (гауссово ядро)')

plt.xlabel('Соппротивление сенсора PT08.S5(03)')
plt.ylabel('Плотность вероятности')
plt.title('Гистограмма и ядерная оценка плотности (KDE) сопротивления сенсора')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

Получившийся график представлен на Рисунке 6.



**Рисунок 6 — Гистограмма и ядерная оценка сопротивления сенсора**

KDE позволяет увидеть основные пики и характер распределения сопротивления сенсора:

- Основной пик на низких значениях показывает частое появление умеренных уровней озона.
- Вторичные пики могут отражать необычные условия или артефакты измерений.
- Хвост на больших значениях демонстрирует редкие экстремальные сопротивления.

KDE лучше гистограммы раскрывает структуру распределения: наличие двух «типов» урбанизации — высокоурбанизированных анклавов и умеренно урбанизированных стран. Это важно для сегментации и политики.

На основе анализа в предыдущем разделе предположим нормальность. Оценка будет производиться по Формуле 2.12:

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)}. \quad (2.12)$$

Программная реализация представлена на Листинге 31.

Листинг 31 — Программная реализация нормальной плотности

```
mu = col.mean()
sigma = col.std(ddof=1)

kde = gaussian_kde(col)
x_grid = np.linspace(col.min(), col.max(), 1000)

plt.figure(figsize=(10, 6))
sns.histplot(col, bins=50, kde=False, stat='density', alpha=0.6,
color='lightgray', label='Гистограмма')
plt.plot(x_grid, norm.pdf(x_grid, mu, sigma), 'b--', lw=2, label=f'Нормальное
( $\mu={mu:.1f}$ ,  $\sigma={sigma:.1f}$ )')
plt.plot(x_grid, kde(x_grid), 'r-', lw=2, label='KDE')
plt.xlabel('Соппротивление сенсора PT08.S5 (O3)')
plt.ylabel('Плотность')
plt.title('Сравнение: гистограмма, KDE и нормальное распределение')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

Получившийся график представлен на Рисунке 7.




Рисунок 7 — Наложение нормального распределения на графики

Нормальное распределение хорошо аппроксимирует центральную часть данных, где сосредоточены основные значения сопротивления сенсора, но оно не отражает пики и редкие экстремальные значения на больших сопротивлениях, которые видны на KDE. Такая аппроксимация полезна для

оценки среднего и дисперсии, но для анализа выбросов и мультимодальности предпочтительно использовать KDE или другие непараметрические методы.

Для проверки нормальности используем QQ-график — сравнение квантилей выборки с квантилями нормального распределения. Его программная реализация представлена на Листинге 32.

#### Листинг 32 — QQ-Plot

```
plt.figure(figsize=(8, 6))
stats.probplot(col, dist="norm", plot=plt)
plt.title('QQ-график: PT08.S5(O3) vs нормальное распределение')
plt.grid(True, alpha=0.3)
plt.show()
```

Получившийся график представлен на Рисунке 8




Рисунок 8 — Соответствие нормальному распределению

QQ-график подтверждает квазинормальность с искажением на границах (центральная часть лежит на прямой, а также отклонения сверху и снизу).

На основе проведённого анализа данных о сопротивлении сенсора PT08.S5(O3) сформируем 4 статистические гипотезы, релевантные исследованию характеристик сенсора и влияния внешних. Гипотезы проверим с использованием параметрических (t-тест,  $\chi^2$ ), непараметрического критерия Манна–Уитни и критериев на распределение (Kolmogorov-Smirnov). Для каждой рассчитаем p-value, уровень значимости  $\alpha=0.05$ , мощность теста  $(1-\beta)$ , где  $\beta$  — вероятность ошибки II рода), критическое значение.

Гипотеза 1: о среднем уровне сопротивления сенсора.  $H_0$ : Среднее сопротивление сенсора PT08.S5(O3) равно 1000 (типичный усреднённый уровень по данным).  $H_1$ : Среднее  $\neq 1000$ . Тип теста: параметрический t-тест для одного среднего. Он будет рассчитан по Формуле 2.13:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}. \quad (2.13)$$

Программная реализация проверки первой гипотезы представлена на Листинге 33.

*Листинг 33 — t-test о среднем*

```
col = df['PT08.S5(O3)'].replace(-200, np.nan).dropna()

t_stat, p_value = stats.ttest_1samp(col, 1000)
crit_t = round(stats.t.ppf(1 - 0.025, df=len(col)-1), 3)
effect_size = (np.mean(col) - 1000) / np.std(col, ddof=1)
power = round(smp.TTestPower().power(effect_size=effect_size, nobs=len(col),
                                     alpha=0.05, alternative='two-sided'),
3)
beta = round(1 - power, 3)

print(f"t-stat: {t_stat:.3f}, p-value: {p_value:.3f}, crit_t: {crit_t},
power: {power}, beta: {beta}")
```

Были получены следующие результаты:

- t-статистика: 5.451;
- p-value: 0.000;
- уровень значимости  $\alpha$ : 0.05;
- критическое значение: 1.96;
- мощность теста: 1;

- $\beta$  (ошибка II рода): 0.000.

Так как  $p\text{-value} < \alpha$  ( $0.000 < 0.05$ ), нулевая гипотеза  $H_0$  отвергается на уровне значимости 5%. Это означает, что средний уровень исследуемого показателя (например, концентрации СО) статистически значимо отличается от заданного порогового значения (1000). Высокая мощность теста ( $1.000$ ) и отсутствие ошибки II рода ( $\beta = 0.000$ ) подтверждают высокую достоверность вывода.

Результаты указывают на существенное превышение среднего уровня относительно нормативного значения, что свидетельствует о выраженных изменениях в концентрации вещества и подтверждает необходимость дальнейшего анализа факторов, влияющих на вариацию показателя.

Гипотеза 2: о различиях между дневными и ночными измерениями (Манна–Уитни).  $H_0$ : Распределение сопротивления сенсора одинаково днём и ночью.  $H_1$ : Распределения различаются. Тип теста: непараметрический критерий Манна–Уитни, который будет рассчитываться по Формуле 2.14 после ранжировки данных:

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1, \quad (2.14)$$

где  $R_1$  — сумма рангов первой группы.

Программная реализация критерия Манна–Уитни представлена на Листинге 34.

Листинг 34 — Критерий Манна-Уитни

[illegible]



#### Продолжение таблицы 34

```
alpha=0.05,  
alternative='two-sided'), 3)  
beta = round(1 - power, 3)  
print(f"U-stat: {u_stat:.3f}, p-value: {p_value:.3f}, power: {power}, beta:  
{beta}")  
print(f"Размеры выборок – день: {len(day)}, ночь: {len(night)}")
```

Были получены следующие результаты:

- U-статистика: 13098151.000
- p-value: 0.000;
- $\alpha = 0.05$ ;
- критическое значение: 0.000;
- мощность теста: 1.000;
- $\beta$  (ошибка II рода): 0.
- размеры выборок: день — 4870, ночь — 4121

Существует статистически значимое различие в сопротивлении сенсора PT08.S5(O3) между дневными и ночными показателями. Мощность теста максимальная — 1.0, что подтверждает высокую надёжность выявленного эффекта. Это указывает на выраженную зависимость концентрации озона от времени суток и необходимость учитывать эту факторную зависимость при анализе данных.

Гипотеза 3: о нормальности распределения PT08.S5(O3).  $H_0$ : Распределение сопротивления сенсора нормальное.  $H_1$ : Распределение не нормальное. Тип теста: Колмогорова–Смирнова, который рассчитывается по Формуле 2.15:

$$D = \max | \hat{F}_n(x) - F(x) |. \quad (2.15)$$

Программная реализация критерия Колмогорова–Смирнова представлена на Листинге 35.

#### Листинг 35 — Критерий Колмогорова–Смирнова

```
mu, sigma = np.mean(col), np.std(col, ddof=1)  
ks_stat, p_value = stats.kstest(col, 'norm', args=(mu, sigma))  
crit_ks = round(1.36 / np.sqrt(len(col)), 3)
```

Были получены следующие результаты:

- p-value: 0;
- KS-статистика: 0.061;
- $\alpha$ : 0.05;
- критическое значение: 0.014;
- мощность: 1;
- $\beta$ : 0.

Отвергаем  $H_0$  — распределение сопротивления сенсора PT08.S5(O3) не является нормальным. Наблюдается мультимодальность и выраженные пики, что указывает на неоднородность показателей и возможное влияние экстремальных значений в данных.

Гипотеза 4: о дисперсии сопротивления ( $\chi^2$ -тест).  $H_0$ : Дисперсия  $\sigma^2 = 160000$  (из предыдущего анализа).  $H_1$ : Дисперсия  $\neq 160000$ . Тип теста:  $\chi^2$ -тест о дисперсии, который рассчитывается по Формуле 2.16:

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} \quad (2.16)$$

Программная реализация:  $\chi^2$ -теста представлена на Листинге 36.

*Листинг 36 —  $\chi^2$ -тест*

```
n = len(col)
var = np.var(col, ddof=1)
chi2_stat = (n-1) * var / 160000
p_value = round(2 * min(stats.chi2.cdf(chi2_stat, df=n-1),
                                     1 - stats.chi2.cdf(chi2_stat, df=n-1)), 3)
crit_chi_low = round(stats.chi2.ppf(0.025, df=n-1), 3)
crit_chi_high = round(stats.chi2.ppf(0.975, df=n-1), 3)

print(f"Chi²: {chi2_stat:.3f}, p-value: {p_value:.3f}, "
      f"crit_low: {crit_chi_low}, crit_high: {crit_chi_high}")
```

Были получены следующие результаты:

- p-value: 0.615;
- $\chi^2$ -статистика: 8921.998;
- $\alpha$ : 0.05;

- критические значения: 8729.089 / 9254.7;
- мощность: 1;
- $\beta$  (ошибка II рода): 0.

Так как  $p\text{-value} > \alpha$  ( $0.615 > 0.05$ ) и значение  $\chi^2$  находится внутри критического интервала, принимаем  $H_0$ . Это означает, что дисперсия сопротивления сенсора PT08.S5(O3) соответствует предполагаемому значению и данные относительно стабильны по разбросу.

Проведённая проверка статистических гипотез позволила подтвердить достоверность и устойчивость полученных результатов.

Первая гипотеза показала, что среднее значение сопротивления сенсора PT08.S5(O3) статистически значительно отличается от 1000 Ом ( $p\text{-value} < 0.05$ ), что указывает на отклонение среднего уровня измерений от условно принятого базового значения.

Вторая гипотеза выявила статистически значимые различия между дневными и ночными показаниями сенсора ( $p\text{-value} = 0.000$ , мощность теста = 1.0), подтверждая влияние суточных колебаний на концентрацию озона.

Третья гипотеза (тест Колмогорова–Смирнова) показала отклонение распределения от нормального ( $p\text{-value} = 0.000$ ), что согласуется с наблюдаемой мультимодальностью и пиками в данных.

Четвёртая гипотеза подтвердила, что дисперсия выборки не отличается существенно от теоретически заданной ( $p\text{-value} = 0.615$ ), что говорит о стабильности разброса измерений.

Результаты гипотез указывают на достоверность выявленных закономерностей и подчёркивают устойчивость структуры данных при наличии естественной вариативности в показаниях сенсора.

Проведённый анализ параметров распределения сопротивления сенсора PT08.S5(O3) позволяет дать следующую характеристику исследуемым данным. Значения сенсора демонстрируют высокий средний уровень отклика с выборочным средним 1022.91 и медианой 963.00, что отражает типичный уровень озона, регистрируемый в исследуемом периоде. Высокая дисперсия

(158789.73) и стандартное отклонение (398.48) указывают на значительную изменчивость показаний сенсора, с мультимодальностью распределения (мода 825.00 демонстрирует наиболее часто встречаемые значения) и правосторонней асимметрией. Доверительные интервалы для среднего ([1014.67, 1031.14]) и дисперсии ([154248.08, 163535.93]) достаточно узкие благодаря большому объёму выборки, что подтверждает высокую точность полученных оценок и стабильность измерений сенсора.

## **3 ИДЕНТИФИЦИРОВАНИЕ РАСПРЕДЕЛЕНИЯ ИССЛЕДУЕМЫХ ДАННЫХ**

### **3.1 ИДЕНТИФИЦИРОВАНИЕ РАСПРЕДЕЛЕНИЯ С ПОМОЩЬЮ КРИТЕРИЯ СОГЛАСИЯ ПИРСОНА**

Для целевой переменной PT08.S5(O3) (сопротивление сенсора озона) на основе визуального анализа и проверки критериев нормальности было выдвинуто предположение о логнормальном распределении. Данные демонстрируют правостороннюю асимметрию, положительную определённость значений и длинный правый хвост — характерные признаки логнормальности. В качестве альтернативной гипотезы для сравнения выбрано геометрическое распределение.

Критерий  $\chi^2$  (хи-квадрат) Пирсона позволяет проверить, насколько фактическое распределение частот по интервалам (или группам) соответствует ожидаемому распределению и определяется по Формуле 3.1:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \quad (3.1)$$

где  $O_i$  — наблюдаемая частота в  $i$ -м интервале;

$k$  — количество интервалов;

$E_i$  — ожидаемая частота в  $i$ -м интервале.

Приведем формулы для теоретических частот для логнормального распределения.

Для расчёта критерия согласия  $\chi^2$  необходимо определить теоретические (ожидаемые) частоты, то есть количество наблюдений, которое

должно попадать в каждый интервал разбиения при условии, что данные действительно распределены в соответствии с предполагаемой моделью.

Пусть имеется разбиение на  $k$  интервалов, тогда теоретическая ожидаемая частота для  $i$ -го интервала определяется по Формуле 3.2:

$$E_i = n \cdot P_i \quad (3.2)$$

где  $P_i = F(x_{i,\text{right}}) - F(x_{i,\text{left}})$ ;

$F(x_{i,\text{right/left}})$  — теоретическая функция распределения (CDF) предполагаемого распределения.

Если  $X \sim \text{Lognormal}(\mu, \sigma^2)$ , то его функция распределения задаётся Формулой 3.3:

$$F(x) = \Phi\left(\frac{\ln(x) - \mu}{\sigma}\right) \quad (3.3)$$

где  $\Phi()$  — стандартная нормальная CDF.

Теперь приведем теоретические частоты для геометрического распределения.

Геометрическое распределение является дискретным и определяет количество испытаний до первого успеха. Геометрическое распределение задаётся формулой вероятности 3.4:

$$P(X = k) = p(1 - p)^{k-1} \quad (3.4)$$

Теперь вычислим критерии  $\chi^2$  для логнормального и геометрического распределений в Листинге 37.

*Листинг 37 — Вычисление критерия  $\chi^2$  для логнормального и геометрического распределений*

```
print(f"Chi²: {chi2_stat:.3f}, p-value: {p_value:.3f}, "  
      f"crit_low: {crit_chi_low}, crit_high: {crit_chi_high}")  
k = 20  
counts, bin_edges = np.histogram(col, bins=k)  
O = counts  
n = len(col)  
  
mu = np.log(col).mean()  
sigma = np.log(col).std()  
  
E_lognorm = []  
for i in range(k):  
    a, b = bin_edges[i], bin_edges[i+1]  
    Pi = lognorm.cdf(b, s=sigma, scale=np.exp(mu)) - lognorm.cdf(a, s=sigma,  
scale=np.exp(mu))  
    E_lognorm.append(n * Pi)  
  
E_lognorm = np.array(E_lognorm)  
chi2_lognorm = np.sum((O - E_lognorm)**2 / E_lognorm)  
p = 1 / (1 + col.mean())  
  
E_geom = []  
for i in range(k):  
    a, b = int(bin_edges[i]), int(bin_edges[i+1])  
    Pi = np.sum([p * (1 - p)**(x - 1) for x in range(max(a, 1), max(b, 2))])  
    E_geom.append(n * Pi)  
  
E_geom = np.array(E_geom)  
  
chi2_geom = np.sum((O - E_geom)**2 / E_geom)  
  
chi2_lognorm, chi2_geom
```

В результате вычисления статистики  $\chi^2$  для двух рассматриваемых распределений были получены следующие значения:  $\chi^2_{lognorm} = 194.51$  и  $\chi^2_{geom} = 6166.68$ .

Сравнение значений статистики  $\chi^2$  показывает, что значение  $\chi^2$  для логнормального распределения составляет 194.51, а значение  $\chi^2$  для геометрического распределения — 6166.68, что более чем в 30 раз больше. Поскольку меньшая статистика  $\chi^2$  означает лучшее соответствие моделируемому распределению, можно сделать однозначный вывод: логнормальное распределение значительно точнее описывает данные сопротивления сенсора PT08.S5(O3), а геометрическое распределение

демонстрирует резкое несоответствие реальным данным и выступает заведомо неверной моделью.

Теперь предоставим код для построения гистограммы с логнормальным распределением в Листинге 38.


*Листинг 38 — Построение гистограммы и логнормальной PDF*

```
col = df['PT08.S5(O3)'].replace(-200, np.nan).dropna()

shape, loc, scale = lognorm.fit(col, floc=0)
x = np.linspace(col.min(), col.max(), 1000)

plt.figure(figsize=(10,6))
plt.hist(col, bins=50, density=True, alpha=0.6, color='lightgray',
label='Гистограмма')
plt.plot(x, lognorm.pdf(x, shape, loc=0, scale=scale), 'r-', lw=2,
label='Логнормальное PDF')
plt.xlabel('PT08.S5(O3)')
plt.ylabel('Плотность')
plt.title('Гистограмма и логнормальная аппроксимация')
plt.legend()
plt.grid(alpha=0.3)
plt.show()
```

Получившийся рисунок представлен на рисунке 9.



**Рисунок 9 — Гистограмма и логнормальная аппроксимация**

Логнормальное распределение хорошо аппроксимирует на наших данных, но оно не отражает пики и редкие экстремальные значения на



больших сопротивлениях, которые видны. Такая аппроксимация полезна для оценки среднего и дисперсии, но для анализа выбросов и мультимодальности предпочтительно использовать более подходящие методы.


Теперь предоставим код для построения гистограммы с геометрическим распределением в Листинге 39.

*Листинг 39 — Построение гистограммы и геометрической PDF*

```
p = 1 / (col.mean())
k = np.arange(1, col.max().astype(int))

plt.figure(figsize=(10,6))
plt.hist(col, bins=50, density=True, alpha=0.6, color='lightgray',
label='Гистограмма')
plt.stem(k, geom.pmf(k, p), linefmt='g-', markerfmt='go', basefmt=" ",
label='Геометрическая PMF')
plt.xlabel('PT08.S5(O3)')
plt.ylabel('Плотность')
plt.title('Гистограмма и геометрическая аппроксимация')
plt.legend()
plt.grid(alpha=0.3)
plt.show()
```

Получившийся рисунок представлен на рисунке 10.



**Рисунок 10 — Гистограмма и геометрическая аппроксимация**

Геометрическое распределение ужасно аппроксимирует на наших данных, в результате геометрическая аппроксимация значительно

переоценивает частоты в области малых сопротивлений и почти полностью игнорирует значения во всей средней и правой части диапазона.

## 3.2 ИДЕНТИФИЦИРОВАНИЕ РАСПРЕДЕЛЕНИЯ С ПОМОЩЬЮ МЕТОДА АНАМАРФОЗ

Метод анаморфоз представляет собой способ проверки согласованности эмпирического распределения данных с предполагаемым теоретическим распределением. Суть метода заключается в преобразовании вероятностной меры таким образом, чтобы исходные данные в координатах преобразованного пространства выстроились вдоль прямой.

Если данные действительно подчиняются выбранному теоретическому распределению, то преобразованные значения должны давать линейную зависимость, а коэффициент детерминации линейной регрессии должен быть близок к 1.

Анаморфоза логнормального распределения представлена преобразованием координат вида (3.5).

$$\ln(f(x)) \sim (\ln(x) - (\mu - \sigma^2))^2 \quad (3.5)$$

где  $f(x)$  — плотность вероятности логнормального распределения.

Реализация построения анаморфозы логнормального распределения представлена в Листинге 40.

*Листинг 40 — Построение анаморфозы логнормального распределения*

```
ecdf = ECDF(col)
p = ecdf(col).copy()

eps = 1 / (len(col) + 1)
p[p <= 0] = eps
p[p >= 1] = 1 - eps
Z = norm.ppf(p)
X = Z.reshape(-1,1)
y = np.log(col.values)
```

#### Продолжение Листинга 40

```
reg = LinearRegression().fit(X, y)

mu_anamorph = reg.intercept_
sigma_anamorph = reg.coef_[0]
R2 = reg.score(X, y)

print(f"μ (анаморфоза) = {mu_anamorph:.2f}")
print(f"σ (анаморфоза) = {sigma_anamorph:.2f}")
print(f"R² = {R2:.4f}")
plt.figure(figsize=(10,6))
plt.scatter(Z, y, s=10, alpha=0.3)
plt.plot(Z, reg.predict(X), 'r-', lw=2)
plt.xlabel('Z')
plt.ylabel('ln(PT08.S5(O3))')
plt.title('Анаморфоза логнормального распределения')
plt.grid(True, alpha=0.3)
plt.show()
```

Полученный рисунок представлен на рисунке 11.




Рисунок 11 — Анаморфоза логнормального распределения

Были получены следующие параметры:  $\mu = 6.85$ ,  $\sigma = 0.40$ ,  $R^2 = 0.9908$ . Высокий коэффициент детерминации (0.9908) означает почти идеальную линейную зависимость между преобразованными величинами. Это указывает, что данные почти полностью соответствуют логнормальному распределению. Угловой коэффициент  $\sigma = 0.40$  практически совпадает с оценками, полученными ранее (по методу максимального правдоподобия и моментами),

значение  $\mu = 6.85$  также согласуется с предыдущими оценками. Из всего вышесказанного можно сделать вывод, что анаморфоза логнормального распределения является подходящей моделью спрямления данных, а значит логнормальная аппроксимация корректна и достоверна.

Теперь проверим методом анаморфоз геометрическое распределение. Программная реализация построения анаморфозы геометрического распределения представлена в Листинге 41.

*Листинг 41 — Построение анаморфозы геометрического распределения*

```
col_discrete = np.ceil(col - col.min() + 1).astype(int)

ecdf = ECDF(col_discrete)
p = ecdf(col_discrete).copy()


eps = 1 / (len(col_discrete) + 1)
p[p <= 0] = eps
p[p >= 1] = 1 - eps
p_geom = 1 / np.mean(col_discrete)
Z = geom.ppf(p, p_geom)
X = Z.reshape(-1,1)
y = np.log(col_discrete)
reg = LinearRegression().fit(X, y)

mu_geom_anamorph = reg.intercept_
sigma_geom_anamorph = reg.coef_[0]
R2_geom = reg.score(X, y)

print(f"μ (анаморфоза геометрическая) = {mu_geom_anamorph:.2f}")
print(f"σ (анаморфоза геометрическая) = {sigma_geom_anamorph:.2f}")
print(f"R² = {R2_geom:.4f}")

plt.figure(figsize=(10,6))
plt.scatter(Z, y, s=10, alpha=0.3)
plt.plot(Z, reg.predict(X), 'r-', lw=2)
plt.xlabel('Z (геометрическая квантиль)')
plt.ylabel('ln(PT08.S5(O3) дискретная)')
plt.title('Анаморфоза геометрического распределения')
plt.grid(True, alpha=0.3)
plt.show()
```

Полученный рисунок представлен на рисунке 12.



**Рисунок 11 — Анаморфоза геометрического распределения**

Были получены следующие параметры:  $\mu = 6.08$ ,  $\sigma = 0.00$ ,  $R^2 = 0.6297$ . Коэффициент детерминации  $R^2 = 0.6297$  свидетельствует о *частичном*, но не хорошем качестве спрямления. Линейность выражена явно слабее, чем у логнормального распределения. Угловой коэффициент  $\sigma = 0.00$  фактически означает полное отсутствие зависимости между преобразованными квантилями и логарифмами данных, геометрическая модель не может описать масштаб и структуру распределения исследуемой выборки.

В третьем разделе была выполнена идентификация распределения исследуемых данных несколькими независимыми статистическими методами: построением эмпирических оценок распределения, проверкой согласия теоретических и наблюдаемых частот по критерию  $\chi^2$  Пирсона, а также линеаризацией распределения методом анаморфоз. Комплексный анализ распределения сопротивления сенсора PT08.S5(O3) показал согласованность результатов всех использованных подходов.

Построение гистограммы и ядерной оценки плотности продемонстрировало выраженную правостороннюю асимметрию и

характерный длинный правый хвост. Такая форма распределения типична для положительных естественных величин и соответствует свойствам логнормальной модели. Проверка критерием  $\chi^2$  Пирсона дополнительно подтвердила это: статистика  $\chi^2$  для логнормального распределения оказалась существенно ниже, чем для заведомо неверной геометрической модели, что свидетельствует о заметно лучшем соответствии логнормального распределения фактическим данным.

Метод анаморфоз позволил выполнить дополнительную, независимую проверку структуры распределения. В координатах логнормальной анаморфозы удалось добиться почти идеального спрямления, чему соответствует высокое значение коэффициента детерминации  $R^2 = 0.9908$ . При этом  $\mu$  параметры и  $\sigma$ , восстановленные по угловому коэффициенту и свободному члену регрессионной прямой, практически совпали с ранее полученными оценками по ММП и методу моментов, что подтверждает корректность и устойчивость логнормальной модели. Для сравнения, геометрическое распределение не продемонстрировало качественного спрямления: коэффициент детерминации составил лишь  $R^2 = 0.6297$ , а значение углового коэффициента оказалось равным нулю, что указывает на полное несоответствие этой модели реальной структуре выборки.

Таким образом, результаты всех применённых методов — графических, параметрических, непараметрических и линейных преобразований — показывают, что исследуемые данные имеют логнормальную природу. Сопротивление сенсора характеризуется положительной областью значений, высокой изменчивостью, выраженной положительной асимметрией и длинным правым хвостом, что типично для логнормально распределённых физических и природных процессов. Используемые в разделе методы позволили не только идентифицировать форму распределения, но и подтвердить стабильность оценок параметров, что важно для последующего моделирования, прогнозирования и оценки поведения сенсора в реальных условиях.

## 4 ЗАКЛЮЧЕНИЕ

В ходе выполненной работы был проведён комплексный статистический анализ данных концентрации озона, включающий предварительное изучение целевого и вспомогательного признаков, проверку статистических гипотез и идентификацию распределения. Все поставленные задачи были выполнены, а полученные результаты обеспечили глубокое понимание структуры данных и свойств исследуемой величины.

На первом этапе был осуществлён детальный предварительный анализ целевого признака — концентрации озона, измеряемой сенсором PT08.S5(O<sub>3</sub>). Исследование показало, что данные обладают высоким качеством и значительной информативностью: пропуски составляют около 5 %, диапазон значений широк, что отражает разнообразие условий окружающей среды. Полученные выборочные характеристики — среднее, медиана, дисперсия, коэффициент вариации — позволили охарактеризовать данные как высоковариативные с выраженной неоднородностью. Точечные оценки параметров распределения, полученные методами максимального правдоподобия, моментов и Байесовским подходом, практически совпали, что подтверждает устойчивость оценок и корректность используемых методов. Результаты предварительного анализа создают фундамент для более глубокого изучения поведения концентрации озона и её динамики.

Второй раздел был посвящён изучению вспомогательного признака — температуры воздуха. Анализ распределения температуры показал умеренную изменчивость и относительную симметричность данных, что делает температуру надёжным и стабильным фактором для последующего моделирования взаимосвязей. Точечные оценки параметров распределения также оказались согласованными между собой, что подтверждает корректность статистической обработки и устойчивость структуры выборки. Этот результат важен, поскольку температура является одним из ключевых факторов, влияющих на формирование концентрации озона.

В блоке проверки статистических гипотез была подтверждена достоверность основных закономерностей, выявленных на предыдущих этапах исследования. Было получено статистически значимое отличие среднего значения концентрации от базового уровня, доказано существование различий между дневными и ночными показаниями сенсора, а также установлено отклонение распределения данных от нормального закона. Вместе с тем проверка гипотезы о дисперсии показала стабильность разброса данных. Эти результаты демонстрируют, что исследуемая величина обладает выраженной асимметрией и существенной вариативностью, но при этом остаётся достаточно устойчива для применения параметрических методов анализа.

Окончательная идентификация распределения, выполненная в третьем разделе, включала графические методы, проверку согласия по критерию  $\chi^2$  Пирсона и метод анаморфоз. Все применённые подходы показали согласованность результатов: распределение сопротивления сенсора обладает выраженной правосторонней асимметрией и длинным тяжёлым хвостом, что характерно для логнормального распределения. Логнормальная модель продемонстрировала близкое соответствие эмпирическим данным как по графическим критериям, так и по  $\chi^2$ -статистике, в то время как геометрическое распределение показало значительно худшее согласие. Дополнительная проверка методом анаморфоз выявила почти идеальное линеаризованное представление данных ( $R^2 \approx 0.99$ ) и обеспечила параметры, совпадающие с результатами других методов оценки. Это окончательно подтверждает логнормальную природу исследуемой величины.

Таким образом, проведённый анализ позволил получить целостное представление о свойствах и распределении концентрации озона. Данные характеризуются высокой изменчивостью, положительной асимметрией и логнормальной структурой распределения, что типично для природных процессов, формирующихся под воздействием множества независимых мультипликативных факторов. Все выполненные задачи от предварительного



анализа до проверки гипотез и идентификации распределения были успешно решены, а итоговые результаты могут служить надёжной основой для дальнейшего моделирования, прогнозирования и изучения динамики концентрации озона в реальных условиях.

## СПИСОК ИСТОЧНИКОВ

1. UCI [Электронный ресурс]: Air Quality — режим доступа на сайт: <https://archive.ics.uci.edu/dataset/360/air+quality>
2. NumPy Documentation [Электронный ресурс] Основные инструменты анализа массивов данных. — режим доступа на сайт: <https://numpy.org/>
3. Matplotlib Documentation [Электронный ресурс] Визуализация данных. — режим доступа на сайт: <https://matplotlib.org/>
4. SciPy [Электронный ресурс] Documentation Statistical Functions (scipy.stats). — режим доступа на сайт: <https://scipy.org/>
5. Иванов Б. Н. Теория вероятностей и математическая статистика [Электронный ресурс]: учебное пособие. Санкт-Петербург: Лань, 2019. — режим доступа на сайт: <https://e.lanbook.com/book/113901>
6. Гмурман В. Е. Теория вероятностей и математическая статистика. — М.: Высшая школа, 2010.
7. Кричевский Р. Е. Математическая статистика: учебник. — М.: МГУ, 2012.
8. Shapiro, S.S., Wilk, M.B. (1965). *An analysis of variance test for normality*. [Электронный ресурс] — режим доступа на сайт: <https://www.jstor.org/stable/2333709>
9. Anderson, T.W., Darling, D.A. (1954). *A test of goodness of fit*. — режим доступа на сайт: <https://www.jstor.org/stable/2281537>
10. Н. И. Чернова МАТЕМАТИЧЕСКАЯ СТАТИСТИКА: учебное пособие — Сибирский государственный университет телекоммуникаций и информатики, 2009.
11. С. Е. Демин, Е. Л. Демина МАТЕМАТИЧЕСКАЯ СТАТИСТИКА: Учебное издание — Нижнетагильский технологический институт, 2016.